# ML for Security – лаба 1

#### Возможные варианты заданий

- 1. Базовый контест (делают все хоть как-то)
  - 1.1. Обучить модель без каких-либо дополнительных условий, которая должна наилучшим образом отработать на тестовой выборке преподавателя с точки зрения F-меры
- 2. Вторичные контесты
  - 2.1. Максимально логичным образом обучить качественную модель, использующую для работы только 10 признаков из всего исходного множества.
  - 2.2. Обучить модель, обеспечивающую вероятность пропуска бота на уровне не выше 0.03, и имеющую насколько возможно низкую вероятность ложного обнаружения.
- 3. Углубленное аналитическое исследование по имеющимся данным
  - 3.1. Тем или иным способом выполнить сравнительное исследование значимости различных признаков применительно к произвольному фиксированному классификатору.
  - 3.2. Синтезировать 3 или более собственных признаков на основе имеющихся и показать, что они имеют какие-либо преимущества перед хотя бы какими либо из базовых признаков.
  - 3.3. Выбрать один базовый тип ML-модели на свой вкус (SVM, дерево решений, случайный лес, градиентный бустинг и пр.) и провести ROC-анализ в зависимости от её гиперпараметров.
  - 3.4. Провести исследование влияние параметров обучения на недо- и переобученность модели.

### Формат функции классификации

def classify(modelFileName, dataFileName)

# modelFileName – имя файла, из которого будут загружены параметры обученной ML-модели (например, 'model.txt')

# dataFileName — имя CSV-файла с данными для анализа, которые нужно классифицировать. Файл имеет ту же структуру, что и файл обучающей выборки. Каждая строка файла (кроме заголовочной) содержит признаки одного пользователя.

# return - Numpy-Array с результатами классификации (ширина - 1, высота равна количеству содержательных строк в dataFileName)

#### Описание набора признаков

## Признаки, взятые непосредственно из профиля пользователя

Название признака	Описание
statuses_count	Количество твитов пользователя
followers_count	Количество подписчиков пользователя
friends_count	Количество подписок пользователя
favourites_count	Количество твитов в разделе понравившихся
listed_count	Количество твитов в разделе закрепленных твитов
is_default_profile	Использует ли профиль изображение по умолчанию
is_verified	Верифицирован ли данный аккаунт
is_profile_use_background_image	Использует ли аккаунт фоновое изображение для своей страницы

# Подсчитанные признаки

Название признака	Описание
user_age	Время существования аккаунта в днях
tweet_freq	Отношения числа твиттов к времени существования аккаунта
followers_growth_rate	Отношение числа подписчиков к времени существования аккаунта
friends_growth_rate	Отношение числа подписок к времени существования аккаунта
favourites_growth_rate	Отношение числа понравившихся твиттов к времени существования аккаунта
listed_growth_rate	Отношение числа твиттов из раздела закрепленных к времени существования аккаунта
followers_friends_ratio	Отношение числа подписок к числу подписчиков
screen_name_length	Длина ника пользователя
num_digits_in_screen_name	Количество цифр в нике пользователя
length_of_name	Длина имени пользователя
num_digits_in_name	Количество цифр в имени пользователя
description_length	Длина описания аккаунта пользователя